TÓPICOS ESPECIAIS EM COMPUTAÇÃO VIII

Classificação da Ocupação do Estacionamento com YOLO26

Alta, meio-termo ou baixa ocupação — Campus Anglo, UFPel

Prof. **Marcelo da Silva Dias**

Christian Rodrigo Miritz Kringel · Henrique Colares Versiani · Vinicius Hallmann · Thiago Dias Mazzoni

CIÊNCIA DA COMPUTAÇÃO · ENGENHARIA DA COMPUTAÇÃO · UNIVERSIDADE FEDERAL DE PELOTAS

ROTEIRO

O que vamos apresentar

1. Alterações no dataset
2. Caracterização e divisão do dataset
3. Configuração do experimento
4. Curvas de treinamento e validação
5. Acurácia top-1 no teste
6. Métricas por classe e F1 macro
7. Matriz de confusão
8. Galeria de erros
9. Validação × teste
10. Conclusão crítica

Em uma frase: transformamos o dataset de detecção em um problema de classificação em três níveis de ocupação, completamos a classe que faltava com imagens sintéticas e avaliamos o modelo uma única vez num teste com 10 fotos reais nunca usadas em nenhuma decisão.

De detecção para classificação

- **Nova tarefa:** em vez de uma caixa por veículo, um rótulo por foto. A classe vem da contagem de carros anotados no pátio: **alta ≥ 36**, **meio-termo 25 a 35**, **baixa ≤ 24**. Motos não contam (ficam em área própria).
- **Imagens artificiais adicionadas:** 11 imagens editadas por nós com IA e 25 imagens em que removemos carros por *inpainting*.

CLASSE	ANTES (REAIS)	REAIS	SINTÉTICAS	FINAL
alta-ocupação	**15**	**24**	**0**	**24**
meio-termo	**11**	**12**	**10**	**22**
baixa-ocupação	**2**	**1**	**26**	**27**
Total	**28**	**37**	**36**	**73**

O problema que motivou tudo

Nas nossas coletas o pátio quase nunca estava vazio. Existe **uma única foto real de baixa ocupação**. Sem dados sintéticos, a classe nem existiria no treino.

Antes = as 28 fotos anotadas apresentadas no trabalho anterior, já agrupadas pela regra de contagem. Ficou mais balanceado no total (24 / 22 / 27), mas só com imagens sintéticas: entre as fotos reais o desbalanceamento é extremo (24 / 12 / 1).

Como geramos as imagens sintéticas



Original (alta, 39 carros). Foto real usada como base.



Inpainting → meio-termo. SAM recorta o contorno do carro e da sombra; o LaMa preenche o asfalto.



Inpainting → baixa. Mais carros removidos da mesma foto, até ficar com ≤ 24.

- **Controle de qualidade:** todas as imagens foram revisadas a olho; 16 reprovadas por borrões, manchas ou postes e globos de luz apagados junto com o carro.
- **Veículos não anotados** (achados por um detector Faster R-CNN) são protegidos e nunca removidos.
- **Efeito esperado:** dar ao modelo exemplos de baixa e de meio-termo com o mesmo enquadramento das fotos reais.
- **Risco conhecido:** o modelo aprender o “borrão do inpainting” em vez da ocupação. Por isso as variantes extras (mais cópias da mesma cena) foram descartadas.

A versão final e a divisão

CLASSE	TREINO	VALIDAÇÃO	TESTE	TOTAL
alta-ocupação	**12**	**6**	**6**	**24**
meio-termo	**10** (6 reais)	**3**	**3**	**16**
baixa-ocupação	**18** (0 reais)	**0**	**1**	**19**
Total	**40 (68%)**	**9 (15%)**	**10 (17%)**	**59**

Só fotos reais em validação e teste (25% das 37 fotos em cada). As sintéticas só entram no treino; 14 de inpainting ficaram de fora porque a foto de origem está na validação ou no teste.

Está balanceado?

No treino, sim (12 / 10 / 18). No teste, não: 6 de alta, 3 de meio e **1 de baixa**, que vira 0% ou 100% de recall com um único acerto.

Classes visualmente parecidas

Alta e meio são o mesmo pátio com poucos carros de diferença, e os limites de 25 e 36 carros são arbitrários. Oclusão e carros pequenos ao fundo dificultam até a contagem humana.

Como garantimos que o teste é independente

Divisão por sequência

Fotos tiradas com menos de 20 s de diferença mostram os mesmos carros. Elas formam um grupo (18 grupos nas 37 fotos) e o grupo inteiro vai para o mesmo conjunto.

Imagem editada fica junto da foto original

Cada imagem de inpainting é uma foto real com carros apagados. Ela só entra no treino se a foto original também estiver no treino. Se a original está no teste, o modelo já teria visto aquela cena: por isso **14 imagens de inpainting foram descartadas**.

De qual foto saiu cada imagem de IA?

O nome das 11 imagens de IA não diz de qual foto elas vieram. Comparamos o fundo (prédio, postes, guarda-corpo) com cada foto real para achar a original. **4 delas vieram de fotos que não estão no treino**: 2 da validação e 2 do teste.

Mantivemos as 11 mesmo assim

Pela regra do card de cima, essas 4 deveriam sair. Mas elas eram a nossa principal fonte de exemplos de baixa ocupação. Por isso ficaram, e **mostramos o resultado do teste com e sem as 2 fotos afetadas** (08.06.39 e 12.34.44).

Por que isso importa: se a mesma cena aparece no treino e no teste, o modelo é avaliado em algo que já viu e a nota fica inflada. A primeira versão do `split.py` sorteava imagem por imagem e caía exatamente nesse problema.

Configuração do notebook e escolha dos dados de treino

```
model     yolo26n-cls.pt # menor modelo, já pré-treinado
epochs    30    # passadas pelo treino
imgsz     224   # tamanho da imagem (px)
batch     8     # imagens por passo
seed      0     # sorteios fixos: repetível
patience  30    # sem parada antecipada
fliplr    0.0   # não espelha as fotos
device    cpu   # treino levou 95 s
```

É a configuração do notebook da disciplina. O modelo já sabe reconhecer formas (pré-treinado no ImageNet) e só aprende as nossas 3 classes. Testamos imagens maiores, espelhamento e um modelo maior: **nenhum melhorou, então mantivemos**.

QUAIS IMAGENS SINTÉTICAS USAR? DECIDIDO POR VALIDAÇÃO CRUZADA

Com poucas fotos, uma divisão só depende de sorte. Então separamos as **27 fotos reais que não estão no teste** em 5 partes e treinamos 5 vezes, cada vez avaliando numa parte diferente:

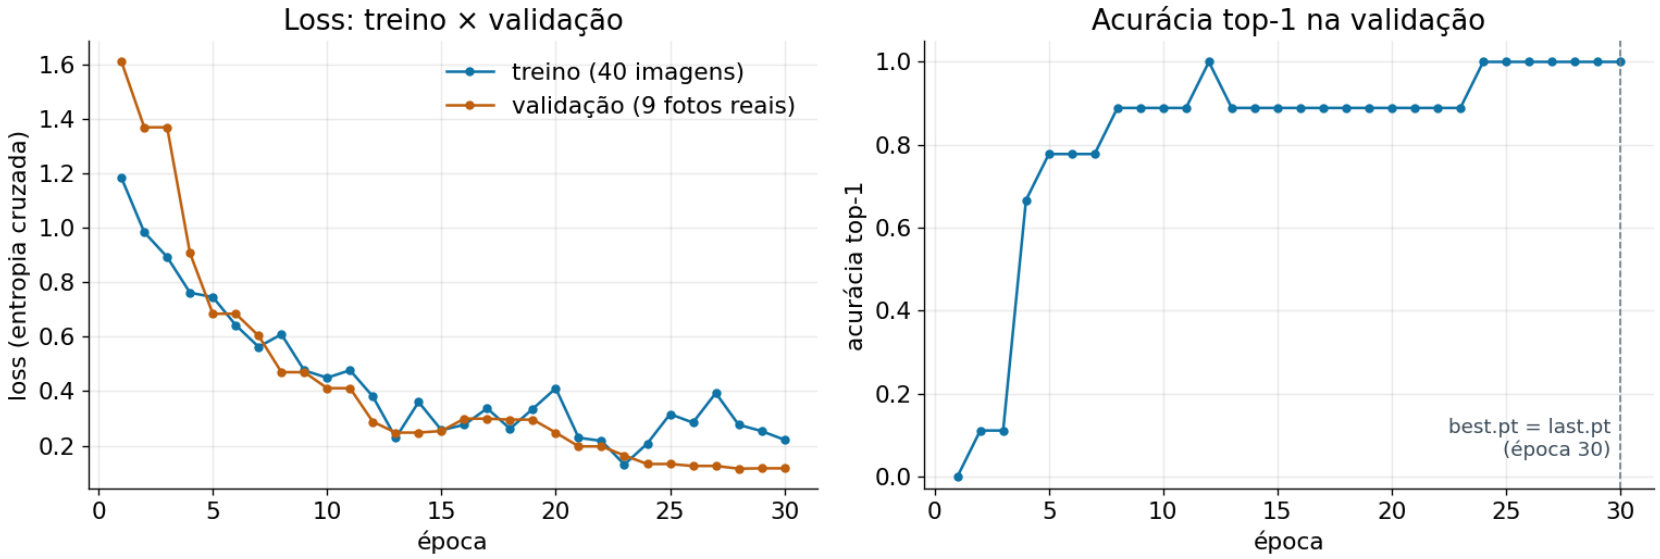


... até a parte 5; tudo repetido com 3 sementes = 15 treinos por linha da tabela

TREINO COM	ACURÁCIA MÉDIA
só fotos reais	**72,8%**
+ editadas por IA	**75,3%**
+ inpainting	**75,3%**
+ IA + inpainting (escolhido)	**72,8%**
+ IA + inpainting + variantes	**75,3%**

Uma foto a mais ou a menos já muda 3,7 pontos: **na prática, todas empatam**. As sintéticas não pioram o modelo, e são a única forma de ele ver baixa ocupação no treino (a única foto real de baixa está no teste). Por isso usamos IA + inpainting.

O treino convergiu, sem sinal de overfitting



results.csv do treino oficial (treino: 40 imagens; validação: 9 fotos reais). Top-5 omitida: com 3 classes é sempre 100%.

- **Loss de treino** (o erro nas imagens de treino) cai de 1,18 para cerca de 0,2: o modelo está aprendendo. Oscila porque cada passo usa só 8 imagens, com recortes e cores sorteados.
- **Loss de validação** (o erro em fotos que o modelo não treina) cai junto, de 1,61 para 0,12, e não volta a subir. Se subisse, seria sinal de que o modelo está decorando o treino (overfitting).
- **Acurácia de validação** chega a 100% na época 12, cai para 89% (1 erro em 9 fotos) e volta a 100% da época 24 em diante.
- A YOLO guarda o `best.pt` (época com melhor validação) e o `last.pt` (última época). Como as últimas épocas empatam em 100%, ela atualiza o best.pt a cada empate: **no fim, os dois são o mesmo modelo**.

5 · ACURÁCIA TOP-1 NO TESTE

8 acertos em 10 fotos reais: 80%

PESOS	ÉPOCA	TOP-1 VALIDAÇÃO	TOP-1 TESTE (ACERTOS / IMAGENS)
`best.pt`	30	**100% (9 / 9)**	**80% (8 / 10)**
`last.pt`	30	**100% (9 / 9)**	**80% (8 / 10)**
Referência: sempre “alta”	—	**—**	**60% (6 / 10)**
best.pt sem as 2 fotos com versão editada no treino	**30**	**—**	**88% (7 / 8)**

É bom para o problema?

Supera a referência em 2 fotos (20 pontos). Mas com 10 imagens cada foto vale 10 pontos: o intervalo de confiança de 95% de 8/10 vai de **49% a 94%**.

best × last

São a mesma época (a validação empatou em 100% até o fim), então dão o mesmo resultado. O modelo oficial continua sendo o `best.pt`.

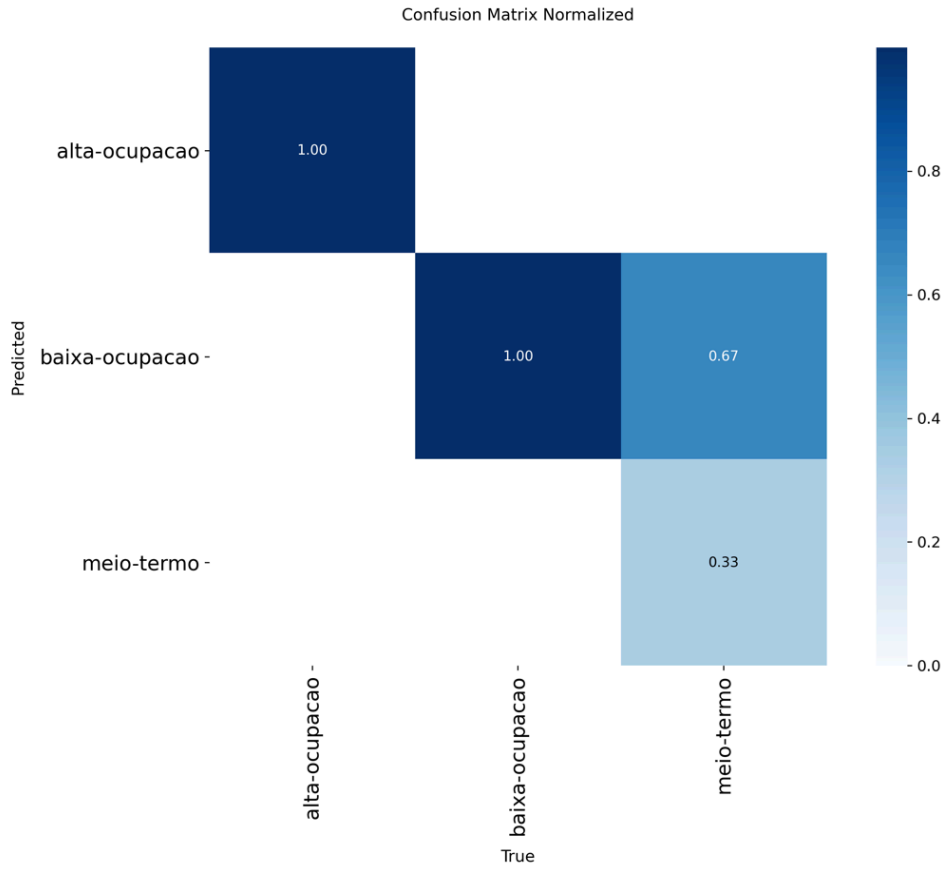
A média esconde o meio-termo

CLASSE	PRECISÃO	RECALL	F1	Nº (TESTE)
alta-ocupação	**1,00**	**1,00**	**1,00**	**6**
meio-termo	**1,00**	**0,33**	**0,50**	**3**
baixa-ocupação	**0,33**	**1,00**	**0,50**	**1**
Média macro	**0,78**	**0,78**	**F1 macro 0,67**	**10**

Calculado a partir do `previsoes_teste.csv` (best.pt). A acurácia do CSV (80%) bate com a do `model.val(split="test")`.

- **Pior F1 e menor recall:** meio-termo, com 1 acerto em 3.
- **Mais falsos positivos:** baixa. O modelo previu baixa 3 vezes e acertou 1 (precisão 0,33).
- **Top-1 80% × F1 macro 0,67:** a acurácia é puxada pela alta, que é 60% do teste e perfeita. O F1 macro dá o mesmo peso às três classes e mostra o problema.
- Relação com os dados: meio e baixa são as classes com **menos fotos reais** no treino (6 e 0).

Meio-termo vira baixa



runs/.../teste_best/. Colunas = classe verdadeira, linhas = prevista; cada coluna soma 1.

- **Único par confundido:** meio-termo → baixa (2 de 3 fotos de meio). Nenhuma confusão envolvendo alta.
- **O modelo puxa para baixa**, não para alta. Na validação cruzada, o erro típico era meio → alta.
- **Hipótese:** as 18 imagens de baixa do treino são sintéticas, feitas apagando carros de fotos de alta e de meio. Pátio com "buracos" de asfalto passou a significar baixa, e uma foto real de meio também tem muito asfalto livre.
- As três classes são o mesmo pátio, o mesmo fundo e a mesma luz: a única diferença é quantos carros há, algo que um classificador de imagem inteira não conta explicitamente.

Um erro confiante explicado pelo dataset



ERRO · 86% **08.06.39 (teste)** — real: meio-termo (27 carros), previsto: baixa.

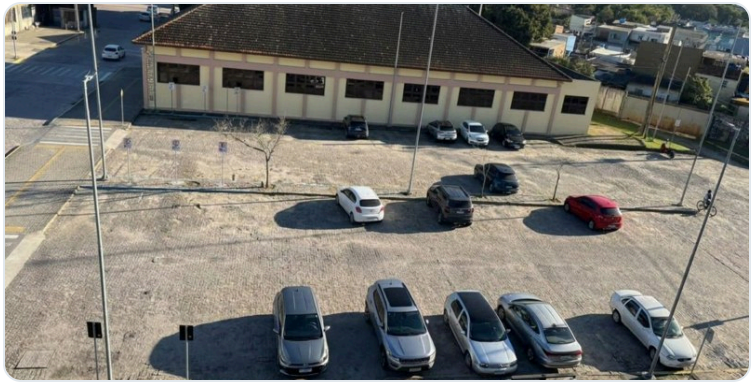


image004 (treino, rótulo baixa) — a mesma foto, editada com IA para remover carros.



ERRO · 45% **08.33.12 (teste)** — real: meio-termo, previsto: baixa.

ERRO DE ALTA CONFIANÇA

- O modelo viu no treino **exatamente esta cena** com o rótulo baixa. Mesmo prédio, mesma luz, mesma sombra: só faltam carros.
- É o vazamento que decidimos aceitar, e aqui ele **atrapalhou**. Sem as 2 fotos afetadas, o teste dá 7 / 8.

ERRO DE BAIXA CONFIANÇA

- Muitos carros pequenos e encobertos ao fundo, pelos globos e pelos postes: fica na fronteira entre meio e baixa até para nós.
- Confiança de 45%: o modelo estava em dúvida, o que é coerente com uma imagem ambígua.

100% na validação, 80% no teste

100%
validação (9 / 9)
IC 95%: 70% a 100%

80%
teste (8 / 10)
IC 95%: 49% a 94%

20
pontos de diferença
= 2 fotos

~10
pontos por foto
nos dois conjuntos

Compatível com o tamanho dos conjuntos?

Sim. Os intervalos se sobrepõem bastante: com 9 e 10 imagens, 2 fotos de diferença é o esperado só pelo sorteio.

Conjuntos diferentes

A validação não tem nenhuma foto de baixa e tem 6 das 9 de alta (a classe mais fácil). O teste tem as fotos difíceis: 3 de meio e a única de baixa.

Escolha pela validação

Aqui pesou pouco, porque todas as últimas épocas empataram em 100%. A validação saturada não consegue diferenciar épocas.

Atenção

Os dois erros do teste vêm de causas identificadas (vazamento e fronteira), mas uma diferença pequena não provaria que o modelo generaliza.

Promissor, mas não comprovado

O QUE OBSERVAMOS

- **Satisfatório só em parte:** 80% contra 60% da referência, alta perfeita, mas meio-termo com recall de 33%.
- **Mais fácil:** alta. **Mais difíceis:** meio-termo, que vira baixa, e a própria baixa, que tem 1 foto real e cuja métrica depende de um único acerto.
- **Generaliza?** Não dá para afirmar: 10 fotos de teste, um único local, horários parecidos e uma classe aprendida quase toda com imagens sintéticas.

O QUE MUDARÍAMOS

- **Fotos reais de pátio vazio** (noite, fim de semana, férias): é a mudança de maior impacto.
- **Revisar a contagem** das fotos perto dos limites de 25 e 36 carros: um rótulo errado já distorceu uma conclusão nossa.
- Gerar sintéticas só a partir de fotos do treino, eliminando o vazamento.
- Comparar com **detecção + contagem**: o dataset de caixas já existe e a classe sai direto da contagem.

Principal aprendizado: os maiores efeitos no resultado vieram dos dados (rótulo errado, vazamento entre conjuntos, cópias da mesma cena), não dos hiperparâmetros.



Obrigado!

Classificação da ocupação do estacionamento — Campus Anglo

CÓDIGO E DATASET

github.com/ChristianKringel/tec-viii

Christian Rodrigo Miritz Kringel · Henrique Colares Versiani
Vinicius Hallmann · Thiago Dias Mazzoni