



TÓPICOS ESPECIAIS EM COMPUTAÇÃO VIII

# Construção de um Dataset para Detecção de Ocupação de Vagas

Estacionamento do Campus Anglo — UFPel

---

Prof. **Marcelo da Silva Dias**

Christian Rodrigo Miritz Kringel

Henrique Colares Versiani

Vinicius Hallmann

Thiago Dias Mazzoni

# O que vamos apresentar

---

1 Descrição do dataset

3 Classes e distribuição

5 Qualidade e consistência

7 Considerações finais

2 Método de aquisição

4 Anotações e critérios

6 Organização dos arquivos

8 Links do dataset

**Em uma frase:** fotografamos o estacionamento da frente do Anglo em vários dias, horários e ângulos, e anotamos cada veículo estacionado com *bounding boxes* no formato YOLO — 1.097 caixas em 28 imagens.

# O que as imagens representam

30

imagens coletadas no total

28

imagens anotadas  
(2 descartadas por repetição)

1.097

bounding boxes anotadas

39,2

média de veículos por imagem

## Cena registrada

O estacionamento localizado na **frente do Campus Anglo da UFPel**, entre o prédio principal e a biblioteca. Cada foto é uma visão elevada do pátio inteiro, com os veículos estacionados e as vagas livres visíveis na mesma cena.

## Objetivo

Reunir dados reais desse estacionamento para **treinar um modelo de detecção capaz de identificar vagas disponíveis a partir de imagens**. Detectando os veículos que ocupam o pátio, é possível inferir por diferença quais vagas estão livres.

## Por que esse local

Pátio de uso intenso, com ocupação que varia bastante ao longo do dia — o que dá variedade natural ao dataset.



**Cena típica do dataset.** Pátio praticamente lotado em manhã de sol; as três fileiras de veículos e o prédio da biblioteca ao fundo aparecem em quase todas as imagens.

# Como e onde as imagens foram obtidas

- **Coletadas pelo próprio grupo.** Nenhuma imagem veio de banco público, internet ou dataset de terceiros — todas as 30 fotos foram tiradas pelos integrantes.
- **Equipamento:** celulares pessoais dos quatro integrantes, com câmeras e resoluções diferentes. Isso aparece no dataset como variação de resolução e de qualidade de imagem.
- **Pontos de captura:** janelas e passarelas dos andares superiores do prédio do Anglo, sempre em vista elevada, mas com enquadramentos e alturas distintas.
- **Distribuição temporal:** fotos tiradas em **dias diferentes** (07, 09 e 15 de setembro) e em **horários diferentes**, capturando o pátio cheio e quase vazio.
- **Condições de clima:** registros em dias de sol aberto, céu parcialmente nublado e céu totalmente encoberto — variando sombra, contraste e temperatura de cor.

## Por que essa variação importa

Múltiplos ângulos, climas e câmeras evitam que o modelo aprenda uma única configuração fixa de cena. A diversidade foi buscada de propósito, e não um acaso da coleta.

## RESOLUÇÕES PRESENTES NO DATASET

1600 × 1200

1280 × 720

1200 × 1600

1280 × 960

1600 × 1227

Reflexo direto dos diferentes aparelhos usados — inclusive uma imagem em orientação retrato.

## Observação sobre os arquivos

As imagens foram reunidas via WhatsApp, então o nome e a data de cada arquivo correspondem ao momento do **envio**, e não necessariamente ao da captura: os metadados EXIF originais foram removidos pelo aplicativo.


# Variação de condições registrada



**Sol aberto, pátio lotado.** Sombras duras e alto contraste.



**Céu encoberto, pátio quase vazio.** Luz difusa e poucos veículos.



**Outro aparelho e enquadramento.** 1280 × 720, ponto de vista mais baixo.



**Orientação retrato.** Enquadramento vertical, de outro ponto do prédio.

# Quais classes foram definidas

- **carro** — qualquer automóvel de passeio estacionado no pátio: hatch, sedã, SUV, picape ou utilitário. É a classe dominante do dataset.
- **moto** — motocicletas estacionadas, concentradas na área lateral reservada a elas, próxima ao muro dos fundos.

## Decisão tomada durante a construção

O arquivo `obj.names` foi criado com quatro rótulos previstos — **carro**, **suv\_picape**, **moto** e **vaga\_livre**. Na prática, separar *carro* de *suv\_picape* gerava dúvida em quase toda imagem (a distinção some na vista de cima) e *vaga\_livre* exigiria demarcar o asfalto vazio, o que fugia do escopo.

**Consolidamos a anotação em duas classes efetivas:** carro e moto.

## E a vaga livre?

A vaga disponível não é anotada diretamente: ela é **inferida** a partir da ausência de veículo detectado sobre a região da vaga. Anotamos a ocupação, não o vazio.



**A classe *moto* na prática.** Recorte da área lateral do pátio, onde aparece a maior concentração de motocicletas do dataset — cinco caixas em uma única imagem.

# 2


classes efetivamente anotadas

# 3

imagens contêm motos

# Distribuição das classes

## Caixas anotadas por classe




| CLASSE | CAIXAS | %     | IMAGENS |
|--------|--------|-------|---------|
| carro  | 1.087  | 99,1% | 28      |
| moto   | 10     | 0,9%  | 3       |
| Total  | 1.097  | 100%  | 28      |

### Desbalanceamento acentuado

Para cada moto anotada há cerca de **109 carros**. É a principal limitação atual do dataset: um modelo treinado assim tende a detectar carros bem e motos mal.

## Veículos anotados por imagem (28 imagens, ordenadas)



- A ocupação do pátio vai de **14 a 63 veículos** por imagem — mediana de 39.
- Essa amplitude é intencional: o dataset cobre desde o estacionamento praticamente vazio até o completamente lotado.

# Tipo de anotação utilizada

- **Bounding boxes** (caixas delimitadoras retangulares, alinhadas aos eixos) — uma caixa por veículo estacionado.
- **Ferramenta: CVAT**, com o projeto compartilhado entre os integrantes para que todos anotassem sob a mesma configuração de classes.
- **Formato exportado: YOLO 1.1** — um arquivo .txt por imagem, com o mesmo nome-base da imagem, mais o obj.names com a lista de classes.
- Coordenadas **normalizadas entre 0 e 1** em relação à largura e à altura da imagem, o que torna a anotação independente da resolução — importante aqui, já que o dataset tem cinco resoluções diferentes.
- Imagem **sem nenhum veículo válido** geraria um .txt vazio; no nosso caso todas as 28 imagens anotadas contêm veículos.

## Estrutura de uma linha do arquivo .txt


```
# <classe> <x_centro> <y_centro> <largura> <altura>
0 0.784062 0.581667 0.048125 0.043333
0 0.828125 0.584583 0.046250 0.049167
0 0.739062 0.547500 0.040625 0.030000
2 0.772500 0.370000 0.016250 0.020000
...
```

## obj.names — índice de cada classe

```
0  carro      ← classe usada
1  suv_picape ← prevista, não utilizada
2  moto       ← classe usada
3  vaga_livre ← prevista, não utilizada
```

**Por que *bounding box* e não *segmentação*:** para decidir se uma vaga está ocupada basta saber *onde* o veículo está, não o seu contorno exato. A caixa é mais rápida de anotar, mais consistente entre quatro anotadores e suficiente para o objetivo do dataset.

# Exemplos de imagens anotadas



**Ocupação alta — 44 caixas.** Três fileiras completas; a densidade força caixas vizinhas a se encostarem e se sobreporem.



**Ocupação mínima — 14 caixas.** Dia encoberto e pátio quase vazio; note que os carros trafegando na rua ao fundo **não** foram anotados.


# CrITÉrios utilizados para anotar

## Regra principal

**Anotar todo veículo estacionado dentro do estacionamento-alvo.** Se está parado ocupando uma posição do pátio, vira caixa. Caso contrário, não.

## Regras derivadas que aplicamos

- **Veículo em movimento não é anotado.** Carro manobrando ou passando pelo pátio não ocupa vaga e ficou de fora.
- **Veículo fora do pátio-alvo não é anotado.** Carros na rua, na calçada ou no estacionamento vizinho ao fundo foram ignorados.
- **A caixa envolve o veículo inteiro visível,** encostando nos limites da carroceria, sem margem sobrando e sem cortar parte do carro.
- **Veículo parcialmente ocluído é anotado** pela porção visível, desde que ainda dê para identificá-lo com segurança como veículo estacionado.
- **Uma caixa por veículo,** mesmo quando dois carros se sobrepõem fortemente na imagem.




**O critério em ação.** Os três veículos parados nas vagas recebem caixa; o carro preto, em movimento pelo pátio, fica sem anotação por não estar ocupando vaga.


## Por que esse recorte

O objetivo do dataset é **ocupação de vaga**, não detecção genérica de veículos. Anotar carros na rua ensinaria o modelo a contar veículos que não têm relação com a disponibilidade do estacionamento.


# Diferentes situações encontradas




**Caso fácil.** Veículos isolados, bem separados e em primeiro plano: caixas justas, sem ambiguidade.



**Caso difícil — oclusão e escala pequena.** Ao fundo e à direita os carros se escondem atrás uns dos outros e ficam com poucos pixels.




**Classe minoritária.** Motos agrupadas na lateral, muito menores que os carros e quase coladas entre si.



**Ângulo e enquadramento distintos.** Outro ponto de captura, com pedestres, postes e o guarda-corpo cruzando a cena.

# Anotações corretas e casos ambíguos



**Anotação correta.** A caixa acompanha os limites da carroceria, inclui retrovisores e para-choque, e não invade o veículo ao lado.

## Como mantivemos o padrão

- **Um único projeto no CVAT**, com lista de classes fixa, evitando rótulos divergentes.
- **Critério combinado antes de anotar** e reafirmado sempre que surgia dúvida nova.
- **Revisão visual de todas as imagens** com as caixas por cima — a pasta preview/ — para flagrar caixas soltas ou veículos esquecidos.
- Na dúvida, **a decisão foi conversada no grupo** e aplicada igual dali em diante.

## Dificuldade 1 — oclusão à direita da cena

Os carros à direita aparecem inclinados e escondidos atrás uns dos outros; definir onde termina um e começa o outro foi a dúvida mais frequente.

## Dificuldade 2 — veículos muito pequenos ao fundo

Nas fileiras distantes cada carro ocupa poucos pixels: um erro de poucos pixels vira uma variação grande em proporção.

## Dificuldade 3 — limite do estacionamento

Veículos parados na borda do pátio, junto à rua ou ao estacionamento vizinho, exigiram decidir caso a caso se estavam no recorte de interesse.

## Dificuldade 4 — obstruções da própria cena

Postes, placas, árvores e o guarda-corpo do prédio cortam veículos ao meio, dividindo visualmente um mesmo carro.

# Como o dataset está estruturado

```
tec-viii/
├── dataset/           # 30 imagens originais (.jpeg)
│   ├── WhatsApp Image ... 08.27.30.jpeg
│   └── ...
├── annotations/      # 28 rótulos YOLO (.txt)
│   ├── obj.names     # lista de classes
│   ├── WhatsApp Image ... 08.27.30.txt
│   └── ...
└── preview/          # 28 imagens com as boxes (.jpg)
    ├── WhatsApp Image ... 08.27.30_bbox.jpg
    └── ...
```

## Vínculo entre imagem e anotação

O pareamento é feito pelo **nome-base do arquivo**: a imagem <nome>.jpeg, seu rótulo <nome>.txt e a conferência visual <nome>\_bbox.jpg. A classe de cada objeto não está no nome do arquivo, e sim no **índice numérico** da primeira coluna do .txt, resolvido pelo obj.names.

## dataset/

As fotos originais, sem edição, corte ou redimensionamento — exatamente como saíram das câmeras.

## annotations/

Exportação YOLO 1.1 do CVAT: um .txt por imagem mais o obj.names. É a pasta consumida no treino.

## preview/

Imagens com as caixas desenhadas sobre a foto. Não entram no treino: servem para **conferência visual**.

## DISPONIBILIZAÇÃO

GitHub · [github.com/ChristianKringel/tec-viii](https://github.com/ChristianKringel/tec-viii)

Google Drive · [drive.google.com/drive/folders/1TzQct9VGSevgPlzMjUzr4fokH7r9WS3x](https://drive.google.com/drive/folders/1TzQct9VGSevgPlzMjUzr4fokH7r9WS3x)

# Dificuldades e decisões do caminho

## PRINCIPAIS DIFICULDADES

- **Curva de aprendizado da ferramenta.** No começo o grupo não dominava o CVAT e o fluxo de anotação; as primeiras imagens foram bem mais lentas que as últimas.
- **Reunir volume de imagens.** Depender de ir ao local, em horários e climas diferentes, limitou o tamanho do dataset a 30 fotos.
- **Oclusão entre veículos**, principalmente na lateral direita das cenas, onde os carros se escondem uns atrás dos outros.
- **Repetição de cena.** Duas imagens ficaram redundantes em relação a outras já anotadas e foram deixadas de fora da anotação.
- **Padronizar o critério entre quatro pessoas** anotando, garantindo que todos marcassem as mesmas coisas do mesmo jeito.

## DECISÕES IMPORTANTES

- **Reduzir de quatro para duas classes efetivas.** *suv\_picape* e *vaga\_livre* foram abandonadas por gerarem ambiguidade e fugirem do escopo.
- **Mudar a técnica de marcação dentro do CVAT.** Começamos desenhando cada caixa manualmente e passamos a usar a **varinha mágica** da ferramenta, que acelerou muito a anotação e deixou as caixas mais justas.
- **Anotar ocupação em vez de vaga vazia**, inferindo a disponibilidade pela ausência de veículo detectado.
- **Não anotar veículos em movimento nem fora do pátio**, mantendo o dataset alinhado ao objetivo de ocupação.
- **Gerar a pasta preview/** como etapa obrigatória de revisão antes de considerar uma imagem concluída.

**Próximos passos naturais:** ampliar o número de imagens, reforçar a classe *moto* para reduzir o desbalanceamento e incluir capturas noturnas e de dias de chuva, condições ainda não cobertas pelo dataset.



# Obrigado!

Dataset de ocupação de vagas — Estacionamento do Campus Anglo

DATASET DISPONÍVEL EM

[github.com/ChristianKringel/tec-viii](https://github.com/ChristianKringel/tec-viii)

[drive.google.com/drive/folders/1TzQct9VGSevgPlzMjUzr4fokH7r9WS3x](https://drive.google.com/drive/folders/1TzQct9VGSevgPlzMjUzr4fokH7r9WS3x)

Christian Rodrigo Miritz Kringel · Henrique Colares Versiani

Vinicius Hallmann · Thiago Dias Mazzoni