GUIA DE APRESENTAÇÃO

Apresentação dos trabalhos

Classificação de imagens com YOLO26:
o que apresentar e o que discutir.



Dataset · Treinamento · Avaliação no teste · Análise crítica

Visão geral

OBJETIVO

Demonstrar compreensão do dataset, das escolhas de treinamento, das métricas e das limitações do modelo. Não basta listar resultados: expliquem **o que eles revelam** sobre o comportamento do modelo, quais classes são mais difíceis e quais limitações o experimento tem. Usem dados reais e justifiquem cada conclusão com métricas, gráficos e exemplos.

A apresentação tem quatro blocos: **Dataset** (tópicos 1 e 2), **Treinamento** (3 e 4), **Avaliação no teste** (5 a 9) e **Análise crítica** (10).

CRITÉRIO CENTRAL

A apresentação será avaliada pelos resultados **e** pela capacidade de interpretá-los criticamente. Um experimento com resultados modestos, mas com análise rigorosa das limitações, confusões e erros, pode demonstrar mais domínio do que um com métricas altas e pouca interpretação.

Orientações gerais

- Usem gráficos e tabelas **legíveis**, com títulos, legendas e nomes das classes, e identifiquem o **conjunto** (treino, validação ou teste) de cada um.
- Diferenciem **resultados observados** de **hipóteses** sobre as causas dos erros.
- Distribuam o tempo: a configuração (tópico 3) pode ser breve; reservem mais tempo para a avaliação e a análise crítica.

1 Alterações no dataset

Antes de treinar, vocês ajustaram o dataset apresentado anteriormente. Descrevam o que mudou: imagens **adicionadas** ou **removidas** (e por quê: baixa qualidade, duplicatas, rótulos errados), **balanceamento** de classes com poucas amostras, classes **criadas, removidas, renomeadas, divididas ou agrupadas**, **rótulos corrigidos** e mudanças nos critérios de coleta ou organização. Se nada mudou, digam isso explicitamente.

O que discutir:

- O que motivou cada modificação?
- Como mudaram a quantidade e a distribuição das imagens: comparem a versão apresentada antes e a versão final (total e por classe). O dataset ficou mais balanceado? Como verificaram?
- Que efeito vocês esperam que essas modificações tenham no modelo?

2 Caracterização e divisão do dataset

Apresentem a versão final do dataset: as **classes**, a **quantidade de imagens** por classe e no total, e a **divisão** entre treino, validação e teste (quantidade e percentual), com o **critério** usado para dividir.

Classe	Treino	Validação	Teste	Total
Classe A	...	...	...	...
Classe B	...	...	...	...
Total	...	...	...	...

O que discutir:

- O dataset está balanceado? Quais classes têm mais e menos amostras, e isso pode influenciar as métricas?
- Há características visuais que tornam algumas classes mais difíceis de distinguir?
- Como garantiram que o teste é **independente**? Verificaram imagens duplicadas ou quase idênticas entre conjuntos? Se há várias imagens do mesmo objeto, indivíduo, local ou sessão de captura, como evitaram espalhá-las entre conjuntos (divisão por grupo)?

3 Configuração do experimento

Apresentem, de forma breve, a configuração usada no treinamento, consultando o `args.yaml`: o **modelo** (`yolo26n-cls.pt`, `yolo26s-cls.pt`...), `epochs`, `imgsz`, `batch`, `seed` e se usaram **pesos pré-treinados**. Não é preciso mostrar o arquivo inteiro.

> NESTA ETAPA
> O foco é **treinar e discutir os resultados**. Usar a configuração padrão (baseline) é perfeitamente adequado; a busca de hiperparâmetros será aprofundada mais adiante na disciplina.

O que informar:

- Se usaram a configuração **padrão** (baseline) ou se **testaram variações** (por exemplo, outro modelo, mais épocas ou outro `imgsz`).
- Se testaram variações: quais foram, e se a escolha final foi feita pela **validação**, e não pelo teste.

4 Curvas de treinamento e validação

Apresentem o `results.png` e expliquem a evolução das perdas e métricas ao longo das épocas, usando os valores do `results.csv`.

O que discutir:

- O treinamento convergiu? A loss de treino diminuiu? Como a `val/loss` se comportou?
- Há indícios de overfitting? O desempenho de validação estabilizou ou continuou melhorando? O treino poderia ter parado antes?

IMPORTANTE

Loss de treino caindo enquanto a `val/loss` sobe de forma **persistente** pode indicar overfitting; considerem o comportamento geral das curvas, não uma época isolada. **Não apresentem a acurácia Top-5:** com no máximo 5 classes, ela é sempre 100% e não informa nada.

Antes da avaliação: previsões no teste

Os tópicos 5 a 9 dependem das previsões **no teste**. O treinamento não as gera: as métricas e matrizes salvas em `runs/classify/train*/` são da **validação**. Façam as etapas abaixo **uma única vez**, sobre o teste reservado, e não ajustem nada depois de olhar o teste: se isso acontecer, ele deixa de ser uma avaliação independente.

1. **Validação no teste dos dois pesos:** rodem `model.val(split="test")` para o `weights/best.pt` **e** para o `weights/last.pt`. Cada execução gera a acurácia Top-1 e as matrizes de confusão do teste numa pasta nova (como `runs/classify/val/`, `val2/`...). Anotem qual pasta é de qual peso.
2. **CSV de previsões (criado por vocês):** a YOLO **não** gera esse arquivo. Escrevam um script que percorre as imagens do teste, faz a previsão com o `best.pt` e salva um CSV (por exemplo, `previsoes_teste.csv`) com uma linha por imagem: **caminho, classe verdadeira** (o nome da pasta), **classe prevista e confiança**. As métricas por classe, o F1 macro e a galeria de erros saem desse arquivo.

IMPORTANTE

O `best.pt` **é o modelo oficial**, porque foi escolhido pela validação, antes de olhar o teste. O `last.pt` é avaliado **só para comparação** (tópico 5): não troquem de modelo por causa do resultado no teste.

VERIFICAÇÃO

A acurácia calculada pelo CSV deve ser praticamente igual à do `model.val(split="test")` do `best.pt`. Uma diferença grande indica erro no procedimento, como classes trocadas ou imagens fora do lugar.

5 Acurácia Top-1 no teste: best.pt e last.pt

Apresentem a acurácia Top-1 no teste dos dois pesos, **com o número de imagens e de acertos** (por exemplo, 412 acertos em 450 imagens: 91,6%). A Top-1 de validação de cada um está no `results.csv`: a do `best.pt` é a da melhor época; a do `last.pt`, a da última.

Pesos	Época	Top-1 validação	Top-1 teste (acertos / imagens)
`best.pt`	…	…	…
`last.pt`	…	…	…

O que discutir:

- O valor é bom para o problema? Comparem com uma referência simples: a acurácia de responder **sempre a classe mais frequente** do teste. Um modelo útil precisa ficar bem acima dela.
- `best.pt` e `last.pt` dão resultados parecidos? Se o `last.pt` for bem pior, as últimas épocas provavelmente pioraram o modelo (overfitting); se forem parecidos, o treino estabilizou. Se o `last.pt` for um pouco melhor no teste, a diferença pode ser só variação do sorteio (tópico 9), e o modelo oficial continua sendo o `best.pt`.
- A Top-1 é uma média de todas as imagens: os tópicos 6 e 7 mostram se ela esconde classes com desempenho ruim.

6 Métricas por classe e F1 macro

Apresentem **precisão, recall e F1** de cada classe e o **F1 macro** (média simples dos F1 das classes, com o mesmo peso para todas), calculados a partir do **CSV de previsões** do `best.pt` (criado por vocês). Eles **não** são gerados pelo treinamento padrão.

Classe	Precisão	Recall	F1-score	Nº de imagens (teste)
Classe A	…	…	…	…
Classe B	…	…	…	…
Média macro	…	…	**F1 macro** …	

O que discutir:

- Qual classe tem o pior F1? E o menor recall? Onde o modelo produz mais falsos positivos (menor precisão)?
- Há diferença expressiva entre a Top-1 e o F1 macro? O que isso indica sobre o desempenho entre as classes?
- Os resultados se relacionam com a quantidade de imagens, o balanceamento ou a semelhança visual entre classes? Interpretem junto com a matriz de confusão.

7 Matriz de confusão normalizada

Apresentem a `confusion_matrix_normalized.png` **do teste** gerada pela validação do `best.pt` (pasta `runs/classify/val*/`), e não a da pasta de treinamento, que é da validação.

> COMO LER
> Na matriz da Ultralytics, cada **coluna** é uma classe **verdadeira** e cada **linha**, uma classe **prevista**. Na versão normalizada, cada coluna soma 1, e a diagonal é o **recall** da classe. Confiram os rótulos dos eixos, que podem variar entre versões.

O que discutir:

- Quais pares de classes são mais confundidos? Quais classes têm maior proporção de erros?
- O modelo tende a prever uma classe no lugar de várias outras?
- Por que essas classes se confundem? Relacionem com as imagens reais: aparência, iluminação, fundo, enquadramento, escala (como raças de cães parecidas, por exemplo beagle e foxhound).

8 Galeria de erros

Mostrem exemplos reais de imagens do teste classificadas incorretamente, com a **imagem**, a **classe verdadeira**, a **classe prevista**, a **confiança** e o **motivo provável** do erro. É **obrigatório** analisar pelo menos **um erro de alta confiança**. Selecionem os erros pelo CSV de previsões, ordenando pela confiança.

O que discutir:

- Por que o modelo errou mesmo estando confiante?
- A imagem é ambígua, de baixa qualidade ou com oclusão? O fundo pode ter induzido o erro? Ela se parece com outra classe?
- O erro revela algum viés do dataset?

9 Validação × teste

Comparem a Top-1 do `best.pt` na **validação** e no **teste**: os dois valores, a diferença entre eles e o tamanho de cada conjunto.

Por que validação e teste dão números diferentes? É normal que deem, por quatro motivos:

- **Escolha pela validação:** o `best.pt` é a época com a **melhor** nota na validação. Ao escolher o maior valor, escolhemos também um pouco de "sorte" daquele conjunto, por isso a validação tende a ser **otimista**. O teste não participou da escolha e não tem esse viés.
- **Imagens diferentes e conjuntos pequenos:** cada conjunto é uma amostra. Com poucas imagens, acertar ou errar algumas muda bastante a nota: com 100 imagens, cada uma vale 1 ponto percentual. Parte da diferença é só variação do sorteio.
- **Diferenças entre os conjuntos:** se a divisão deixou classes, grupos ou condições de captura (luz, fundo, equipamento) em proporções diferentes, um conjunto pode ser mais fácil que o outro.
- **Decisões tomadas olhando a validação:** cada ajuste feito para melhorar a validação (épocas, modelo, imagens removidas) a deixa um pouco mais otimista.

O que discutir:

- A diferença entre validação e teste é compatível com a variabilidade esperada pelo tamanho dos conjuntos?
- Quais dos quatro motivos acima parecem explicar a diferença no experimento de vocês? Há indícios de overfitting ou de conjuntos com distribuições diferentes?

> IMPORTANTE
> Uma diferença pequena entre validação e teste não garante, sozinha, que o modelo generaliza bem.

10 Conclusão crítica

Encerrem respondendo, com base nas métricas, gráficos e exemplos apresentados:

- O modelo teve resultados satisfatórios para o problema? Por quê?
- Quais classes foram mais fáceis e mais difíceis, e quais são as principais limitações do dataset e do modelo?
- Que mudanças no dataset ou no treinamento poderiam melhorar os resultados?
- Os resultados bastam para afirmar que o modelo generaliza para imagens novas?